

114 學年度第二學期 UNIX 系統程式設計：期末專題提案書

1. 專題名稱與選定方向

- 專題名稱：SentinelBox: 基於 MCP 協議之 AI Agent 語義化安全沙盒系統
- 選定方向：AI Sandbox — 安全沙盒系統


2. 動機與背景說明

在生成式 AI 蓬勃發展的現狀下，AI Agent 自主生成並執行程式碼已成為自動化流程的核心。然而，執行未經審核的 LLM 產出代碼存在極高安全風險。傳統沙盒雖能隔離環境，但當執行失敗時，僅能回傳難以理解的核心錯誤碼（如 SIGSYS），導致 AI 無法有效自我修復。

SentinelBox 旨在利用 Linux Kernel 的現代安全機制，結合 MCP，將低階系統訊號轉化為高階語義回饋。這不僅確保了系統安全性，符合構建安全 AI 程式碼執行沙盒的要求，更構建了「執行 → 失敗 → 語義回饋 → 自動修復」的閉環，阻擋惡意行為的同時提升 AI Agent 的健壯性。

3. 系統架構設計圖

本系統分為四個核心層級，融合核心安全機制與監控面板：



4. 預期功能與技術方案


1. Linux Namespace 隔離：實作 PID、Mount、Network、User 等 namespace 隔離。利用 CLONE_NEWUSER 實現 Rootless 操作，結合 pivot_root 與 OverlayFS 確保檔案系統完全隔離。

2. Seccomp-BPF 系統呼叫濾波與語義化回饋：使用 seccomp 限制沙盒內可使用的系統呼叫。攔截到非法操作（如 SIGSYS）時，透過 MCP 服務將錯誤映射為自然語言描述，回饋給 AI Agent 進行修復。
3. Cgroup 資源限制與即時監控：嚴格控制 CPU、記憶體與磁碟 I/O 等資源用量。透過 eBPF 採集數據，實作執行時間與記憶體使用的即時監控面板。
4. 安全日誌與資料庫整合：整合 SQLite 資料庫儲存執行歷史、結果與安全審計日誌，完整記錄沙盒內之行為。
5. 開源專案建置：將工具以獨立專案發布至 GitHub，並提供完整的 README、CONTRIBUTING 指南與 man page 說明文件。

5. 分工說明

- **鍾佳佑 (S1354018)、林政崴 (S1354033)：沙盒核心與安全防禦**
負責實作 Namespace 隔離環境、Seccomp-BPF 安全濾波器，並定義底層錯誤碼至語義的 Mapping 邏輯表。
- **沈泰瑋 (S1354029)：資源遙測與數據持久化**
負責 Cgroup v2 資源限制實作、eBPF 即時效能數據採集，以及 SQLite 安全日誌資料庫管理。
- **陳泰銘 (S1354032)：MCP 轉譯與前端面板**
負責 MCP Server 語義轉譯實作、React 即時監控面板開發，以及 GitHub 專案管理與開源技術文件撰寫。

6. 預計時程表



7. 預期困難與解決方案

- **預期困難：Seccomp 攔截與跨語言非同步處理開銷。**
解決方案：使用 Rust 的異步 Actor Model 處理監控端邏輯，利用共享記憶體進行數據傳輸，避免阻塞隔離引擎。
- **預期困難：確保 Sandbox 防禦機制不被繞過（如無限迴圈或提權）。**
解決方案：實施多層防禦，除了 Namespace，強制執行 Capability Dropping 與 Cgroup 硬上限限制，並預先編寫惡意測試腳本進行壓力測試。